

Descripción de los datos

Fuente

Conjunto de datos	Consolidado de salidas sistema troncal por franja horaria — Octubre 2024
Publicado por	Empresa de Transporte del Tercer Milenio — TransMilenio S.A.
Portal	Datos Abiertos Bogotá — https://datosabiertos.bogota.gov.co/dataset/consolidado-de-salidas-sistema-troncal-por-franja-horaria
Licencia	Creative Commons Atribución 4.0 (CC BY 4.0): se puede usar citando la fuente
Archivo	datos/salidas_troncal_2024_10.csv (11,1 MB), copia sin modificar del original
Periodo	1 al 31 de octubre de 2024

Por qué octubre de 2024. Es el mes completo más reciente publicado y es un mes "normal": no tiene vacaciones escolares largas ni temporada navideña, e incluye un festivo (lunes 14), que sirve para comprobar que el modelo distingue los días de poca demanda.

Relación con el proyecto. En las actividades anteriores el equipo construyó un sistema que calcula rutas en TransMilenio. Estos datos agregan lo que ese sistema no sabía: cuánta gente usa cada estación y a qué hora.

Estructura del archivo original

Formato CSV separado por punto y coma (;) y codificado en Windows-1252.

Columna	Tipo	Descripción	Ejemplo
Línea	texto	Zona troncal de la estación, con su código	(11) Zona K Calle 26
Estación	texto	Estación troncal, con su código	(06000) Portal Eldorado
Acceso de Estación	texto	Puerta o plataforma de la estación por donde sale el usuario	(01) PLAT2 ALIM-DESAL ...
MES	texto	Mes de la medición	OCTUBRE
INTERVALO	texto HH:MM	Inicio de la franja de 15 minutos	07:15
DÍA 01 ... DÍA 31	número	Salidas registradas en esa franja ese día	214
Total general	número	Suma de los 31 días	5180

Cada fila es una combinación de estación, acceso y franja de 15 minutos. El archivo tiene 50.322 filas con datos: 151 estaciones, 568 accesos, 13 zonas y 89 franjas distintas.

Qué es una "salida". Es el registro de un usuario que sale del sistema por el torniquete de una estación troncal. Por eso dice dónde y cuándo **termina** un viaje.

Limpieza y transformación

Todo se hace en [datos_transmilenio.py](#). El archivo original no se modifica.

- 1. **Filas vacías.** El archivo trae 46.133 filas vacías al final y dos columnas sin nombre. Se eliminan.
- 2. **Códigos.** Se quita el código entre paréntesis de zonas y estaciones: (06000) Portal Eldorado pasa a Portal Eldorado.
- 3. **Decimales.** Algunos conteos traen decimales. Como son personas, se redondean.
- 4. **Formato largo.** Se pasa de una columna por día a una fila por estación, día y hora. Se suman los accesos de cada estación y las cuatro franjas de cada hora.
- 5. **Atributos derivados.** - tipo_dia: habil, sabado o domingo_festivo. Se calcula con la fecha (el 1 de octubre de 2024 fue martes) y la lista de festivos (lunes 14 de octubre, Día de la Raza trasladado). - es_portal: verdadero para los portales. En el archivo, los portales Norte, 80 y Usme se llaman "Cabecera", así que también cuentan.
- 6. **Puntos que no son estaciones.** Se descartan los que registran menos de 100 salidas en un día hábil promedio: *Bicicletero Mirador del Paraíso* (2 salidas en todo el mes) y *Corral Portal Dorado* (13 al día). Quedan **149 estaciones**.
- 7. **Horario de servicio.** Los modelos usan solo de 4:00 a. m. a 11:59 p. m. Lo registrado de madrugada es menos del 0,2 % del mes.

Resultado: una tabla de 105.803 filas con estas columnas.

Columna	Descripción
zona	Zona troncal (13 valores)
estacion	Nombre de la estación (149 valores)
día	Día de octubre (1 a 31)
hora	Hora del día (0 a 23)
salidas	Salidas registradas en esa estación, ese día y esa hora
tipo_dia	habil, sabado o domingo_festivo
es_portal	Si la estación es un portal o cabecera

Validación contra la realidad

Tipo de día	Salidas promedio por día
Hábil	2.182.591

Tipo de día	Salidas promedio por día
Sábado	1.638.108
Domingo o festivo	873.027

Las cifras son coherentes con el volumen conocido del sistema troncal. El festivo del 14 de octubre (781.959 salidas) se parece a un domingo y no a un lunes, lo que confirma que la clasificación de días es correcta.

Cómo usa los datos cada modelo

Actividad 3 — Árbol de decisión (supervisado). Cada ejemplo es una estación en una hora de un día. La **etiqueta** es el nivel de demanda: `baja`, `media` o `alta`, según los terciles de las salidas en los días de entrenamiento ($\text{baja} \leq 167 < \text{media} \leq 507 < \text{alta}$). Los **atributos** son la hora, el tipo de día, la zona, si es portal y el tamaño de la estación (sus salidas diarias promedio en los días de entrenamiento). Los días se reparten en orden de calendario: entrenamiento del 1 al 14, validación del 15 al 21 y prueba del 22 al 31.

Actividad 4 — Agrupamiento (no supervisado). No hay etiquetas. Cada estación se describe con un vector de 20 números: la fracción de sus salidas de un día hábil promedio que ocurre en cada hora, de 4 a 23. Se usan fracciones y no conteos para comparar la *forma* del día y no el tamaño de la estación.

Limitaciones

- **Solo salidas.** El archivo no dice dónde empezó cada viaje, así que no permite reconstruir orígenes y destinos.
- **Solo el sistema troncal.** No incluye el SITP zonal. Sí incluye la estación de conexión con el TransMiCable (Cable Portal Tunal).
- **Un solo mes.** Los patrones de octubre pueden cambiar en vacaciones o en diciembre.
- **Salidas sin torniquete.** Si una estación tiene salidas sin validación o hay evasión, esas personas no quedan registradas.