

Pruebas realizadas

- **Fecha de ejecución:** 6 de octubre de 2026
- **Entorno:** Windows 11 Pro · Python 3.13.15 · pandas 3.0.6 · scikit-learn 1.9.1 · scipy 1.18.1 · matplotlib 3.11.2 · pytest 9.1.1
- **Comando:** `uv run pytest -v`
- **Resultado:** 33 de 33 pruebas aprobadas (69 s)

Las pruebas están en la carpeta [pruebas/](#) y cubren tres niveles:

1. **Unitarias con valores calculables a mano.** Verifican que las fórmulas estén bien escritas, por ejemplo que la entropía de un grupo mitad y mitad sea exactamente 1 bit.
2. **De integridad de datos.** Verifican que la limpieza no pierda ni invente información.
3. **De comportamiento del modelo.** Verifican que los modelos aprendan algo útil, sean reproducibles y den resultados con sentido en el mundo real.

1. Carga y limpieza de datos — `test_datos.py` (13 pruebas)

#	Prueba	Qué verifica	Resultado
1	<code>test_el_crudo_no_trae_filas_vacias</code>	Se eliminan las 46.133 filas vacías y las columnas sin nombre del archivo original	Aprobada
2	<code>test_el_crudo_trae_los_31_dias_de_octubre</code>	El archivo tiene una columna por cada día del mes	Aprobada
3	<code>test_quitar_codigo</code>	<code>(06000)</code> Portal Eldorado pasa a Portal Eldorado; un nombre sin código no cambia	Aprobada
4-8	<code>test_tipo_de_dia</code> (5 casos)	1 oct → hábil · 5 oct → sábado · 6 oct → domingo · 14 oct → festivo · 15 oct → hábil	Aprobadas
9	<code>test_el_formato_largo_no_pierde_salidas</code>	Pasar de formato ancho a largo conserva el total (más de 58 millones de salidas)	Aprobada
10	<code>test_no_hay_valores_faltantes_ni_negativos</code>	Ninguna celda vacía y ningún conteo negativo	Aprobada
11	<code>test_se_descartan_los_puntos_que_no_son_estaciones</code>	Todas las estaciones que quedan tienen al menos 100 salidas en un día hábil; el ciclista ya no está	Aprobada

#	Prueba	Qué verifica	Resultado
12	test_los_portales_se_marcan_incluidas_las_cabeceras	Portal Américas y Cabecera Autopista Norte cuentan como portal; Calle 57 no	Aprobada
13	test_un_dia_habil_mueve_mas_gente_que_un_domingo	Prueba de cordura: hábil > sábado > domingo o festivo	Aprobada

2. Árbol de decisión — test_supervisado.py (11 pruebas)

#	Prueba	Qué verifica	Resultado
14	test_entropia_de_un_grupo_puro_es_cero	$H(\text{alta}, \text{alta}, \text{alta}) = 0$	Aprobada
15	test_entropia_de_dos_clases_mitad_y_mitad_es_un_bit	$H(\text{alta}, \text{baja}, \text{alta}, \text{baja}) = 1 \text{ bit}$	Aprobada
16	test_entropia_maxima_con_tres_clases	$H(\text{baja}, \text{media}, \text{alta}) = \log_2 3 \approx 1,585 \text{ bits}$	Aprobada
17	test_ganancia_de_una_pregunta_que_separa_perfecto	Una pregunta que separa las clases del todo gana 1 bit	Aprobada
18	test_ganancia_de_una_pregunta_inutil_es_cero	Una pregunta que no separa nada gana 0 bits	Aprobada
19	test_umbrales_y_etiquetas	Los terciles generan las tres clases; el valor más bajo es "baja" y el más alto "alta"	Aprobada
20	test_los_conjuntos_no_se_mezclan	Entrenamiento, validación y prueba no comparten ningún ejemplo	Aprobada
21	test_el_entrenamiento_tiene_las_tres_clases_balanceadas	Cada clase es entre el 30 % y el 37 % del entrenamiento	Aprobada
22	test_elegir_profundidad_prefiere_el_arbol_mas_simple	Si dos profundidades aciertan casi igual, se elige la menor	Aprobada
23	test_el_arbol_supera_la_linea_base	El árbol acierta al menos 30 puntos más que responder siempre la clase más común	Aprobada
24	test_el_arbol_es_reproducible	Dos entrenamientos iguales dan las mismas predicciones	Aprobada

3. Agrupamiento — `test_no_supervisado.py` (9 pruebas)

#	Prueba	Qué verifica	Resultado
25	<code>test_distancia_euclidiana_a_mano</code>	$d((0,0), (3,4)) = 5$; la distancia de un punto a sí mismo es 0	Aprobada
26	<code>test_cada_perfil_suma_uno</code>	Cada perfil horario es una distribución: sus 20 fracciones suman 1	Aprobada
27	<code>test_la_matriz_tiene_una_columna_por_hora_de_servicio</code>	La matriz de elementos tiene las horas 4 a 23 y más de 140 estaciones	Aprobada
28	<code>test_la_inercia_baja_al_aumentar_k</code>	La inercia decrece con k y la silueta está entre -1 y 1	Aprobada
29	<code>test_kmedias_asigna_todas_las_estaciones</code>	Cada estación recibe un grupo; hay k centroides de 20 dimensiones	Aprobada
30	<code>test_kmedias_es_reproducible</code>	Con la misma semilla, k-medias da los mismos grupos	Aprobada
31	<code>test_los_grupos_tienen_sentido</code>	Portal Américas y Calle 76 caen en grupos distintos, y el del portal es "regreso de la tarde"	Aprobada
32	<code>test_jerarquico_y_kmedias_coinciden_en_casi_todo</code>	Los dos métodos coinciden en más del 90 % de las estaciones	Aprobada
33	<code>test_nombrar_grupo</code>	Un perfil con pico a las 7 se nombra "destino de la mañana" y uno con pico a las 18, "regreso de la tarde"	Aprobada

4. Pruebas de los modelos completos

Además de las automáticas, se ejecutaron los dos scripts completos y se revisaron sus resultados.

Actividad 3 (`uv run python -m supervisado.arbol_decision`)

Medida	Valor
Ejemplos de entrenamiento / validación / prueba	41.720 / 20.860 / 29.800
Profundidad elegida con validación	20

Medida	Valor
Exactitud en los días de prueba (22-31 oct)	91,8 %
Exactitud de la línea base	29,0 %
Precisión / exhaustividad de la clase "alta"	94,4 % / 94,0 %
Clase más difícil	"media" (F1 = 0,877): queda entre las otras dos

Actividad 4 (uv run python -m no_supervisado.agrupamiento)

Medida	Valor
Estaciones agrupadas	149
k elegido (silueta más alta)	2 (silueta = 0,551)
Grupos	Destino de la mañana: 83 estaciones · Regreso de la tarde: 66 estaciones
Coincidencia con el jerárquico (índice de Rand ajustado)	0,947: solo 2 estaciones cambian de grupo

5. Problemas encontrados durante las pruebas

Problema	Causa	Solución
scikit-learn 1.9.1 no cargaba en Windows	El Control inteligente de aplicaciones de Windows 11 bloqueó un archivo DLL de la librería	Se probó con scikit-learn 1.8.0 (mismos resultados); luego se desactivó esa protección en el equipo y se usa la 1.9.1
El primer agrupamiento formaba un grupo con una sola "estación"	El <i>Bicicletero Mirador del Paraíso</i> tiene 2 salidas en el mes y su perfil es ruido	Se descartan los puntos con menos de 100 salidas en un día hábil
Los portales Norte, 80 y Usme no se marcaban como portal	En el archivo se llaman "Cabecera"	<code>es_portal</code> reconoce "Portal" y "Cabecera" (prueba 12)
Primera versión del árbol con 68 % de exactitud	Sin el tamaño de la estación, el árbol no distinguía estaciones grandes y pequeñas de la misma zona	Se agregó <code>salidas_diarias_estacion</code> , calculado solo con los días de entrenamiento
La primera versión elegía la profundidad con los datos de prueba	Error de método: la prueba debe usarse una sola vez	Se separó un conjunto de validación (15-21 oct) para elegir la profundidad